

Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 3

Interagir avec les Grands Modèles de Langages (LLMs)

Contenu

- 1) Principes du Prompt Engineering ; Zero-shot, Few-shot et Prompting ;
- 2) La chaine de pensée (Chain-of-Thought) ;
- 3) Structuration et optimisation des prompts ;
- 4) Gestion des hallucinations et amélioration de la qualité des réponses.

Prompt Engineering avec LangChain

Définition :

L'art de structurer les instructions textuelles pour guider le modèle vers le résultat attendu sans modifier ses poids.

Rôle de LangChain : Permet d'encapsuler les prompts dans des objets dynamiques (**ChatPromptTemplate**) et de les chaîner facilement avec les LLMs et les parseurs de sortie.

Application pratique : Analyse automatique des retours clients du dataset **French Customer Review Sentiment**.

Stratégies de Prompting Avancées

Zero-shot Prompting : Donner la consigne directement au modèle sans exemple préalable. Idéal pour des tâches de classification simples et directes.

Few-shot Prompting : Fournir quelques exemples d'entrées/sorties pour cadrer la syntaxe, le format et le ton des réponses attendues.

Chain-of-Thought (Chaîne de pensée) : Demander au modèle de décomposer son raisonnement étape par étape avant de donner la réponse finale, réduisant ainsi les erreurs sur des cas complexes.

Gestion des Coûts, de la Latence et des Hallucinations

Implications sur les coûts : Plus le prompt et le contexte sont longs (ex: Few-shot avec de nombreux exemples), plus la consommation de tokens augmente.

Contrôle de la température : Utiliser une température basse (temperature= 0.1) pour les tâches de classification et d'analyse factuelle afin de limiter la variabilité et les hallucinations.

Structuration des sorties : Forcer un format de réponse normé (JSON, bullet points*) pour faciliter l'intégration des résultats dans les systèmes d'information (CRM, bases de données).