

Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 3

Interagir avec les Grands Modèles de Langages (LLMs)



Cédric Manouan

Contenu

- 1) Principes du Prompt Engineering ; Zero-shot, Few-shot et Prompting ;
- 2) La chaine de pensée (Chain-of-Thought) ;
- 3) Structuration et optimisation des prompts ;
- 4) Gestion des hallucinations et amélioration de la qualité des réponses.

Prompt Engineering avec LangChain (1/2)

Définition :

L'art de structurer les instructions textuelles pour guider le modèle vers le résultat attendu sans **modifier ses poids** (son fonctionnement interne).

Pour les profils non-techniques ou peu techniques

Maîtriser l'art du dialogue : Comprendre **comment rédiger des instructions claires** pour guider le LLM.

Prompt Engineering avec LangChain (2/2)

Définition :

L'art de structurer les instructions textuelles pour guider le modèle vers le résultat attendu sans **modifier ses poids** (son fonctionnement interne).

Rôle de LangChain : Permet d'encapsuler les prompts dans des objets dynamiques (**ChatPromptTemplate**) et de les chaîner facilement avec les LLMs et les parseurs de sortie.

Application pratique : Analyse automatique des retours clients du dataset **French Customer Review Sentiment**.

Stratégies de Prompting Avancées

Zero-shot Prompting : Donner la consigne directement au modèle sans exemple préalable. Idéal pour des tâches de classification simples et directes.

Few-shot Prompting : Fournir quelques exemples d'entrées/sorties pour cadrer la syntaxe, le format et le ton des réponses attendues.

Chain-of-Thought (Chaîne de pensée) : Demander au modèle de décomposer son raisonnement étape par étape avant de donner la réponse finale, réduisant ainsi les erreurs sur des cas complexes.

Forcer le LLM à décomposer son raisonnement pour éviter les erreurs

Gestion des Coûts, de la Latence et des Hallucinations

Contrôle de la température : Utiliser une température basse (temperature= 0.1) pour les tâches de classification et d'analyse factuelle afin de limiter la variabilité et les hallucinations.

Structuration des sorties : Forcer un format de réponse normé (JSON, bullet points *) pour faciliter l'intégration des résultats dans les systèmes d'information (CRM, bases de données).

Implications sur les coûts : Plus le **prompt** et le **contexte** sont longs (ex: Few-shot avec de nombreux exemples), **plus la consommation de tokens augmente**.

Gestion des Coûts, de la Latence et des Hallucinations

Contrôle de la température : Utiliser une température basse (temperature= 0.1) pour les tâches de classification et d'analyse factuelle afin de limiter la variabilité et les hallucinations.

Structuration des sorties : Forcer un format de réponse normé (JSON, bullet points *) pour faciliter l'intégration des résultats dans les systèmes d'information (CRM, bases de données).


Implications sur les coûts : Plus le **prompt** et le **contexte** sont longs (ex: Few-shot avec de nombreux exemples), **plus la consommation de tokens augmente**.

Lab 3

- ☐ Atelier Prompt Engineering
- ☐ Implication sur les coûts de traitement des requêtes
- ☐ Création d'un "Prompt Library" télécoms pour normaliser les réponses des agents sur les incidents réseau.
- ☐ Test A/B de prompts pour réduire le refus du modèle ("Je ne peux pas aider").

Lab 3

❑ Atelier Prompt Engineering; comment structurer un prompt?




The Anatomy of a Claude Prompt

You are a [ROLE/PERSONA] with expertise in [DOMAIN]. Your tone should be [TONE]. Your audience is [AUDIENCE].

I need you to [SPECIFIC TASK] so that [SUCCESS CRITERIA]. Be direct. No preamble. No fluff.

Here is the background information you need:
<context> [Paste documents, data, or background here] </context> Put long documents at the top. Put your query at the end.

Here are examples of what good output looks like:
<examples> [3-5 input/output pairs covering normal cases and edge cases] </examples> Match this format, tone, and structure exactly.

Before answering, think through this step by step. Use <thinking> tags for your reasoning. Put only your final answer in <answer> tags.

Rules you must follow: Never [thing to avoid]. Always [thing to ensure]. If you are about to break a rule, stop and tell me.

Return your response as [JSON / markdown / table / prose]. Use this exact structure: [structure template]. Wrap your output in <result> tags.

Start your response with exactly this: {"analysis": [Claude continues from here, skipping preamble]}

Opus 4.6 Extended

Role

Task

Context

Examples

Thinking

Constraints

Output Format

Prefill

https://www.linkedin.com/posts/akshay-pachar_the-anatomy-of-a-claude-prompt-how-to-share-7446186048839331840-ULBD/