

Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 4

Génération augmentée par la récupération (RAG)



24 Août – 1er Septembre 2026

Cédric Manouan

Contenu

- 1) Principes du Retrieval-Augmented Generation (RAG) ;
- 2) Construction de bases de connaissances ;
- 3) Recherche sémantique et vectorisation ;
- 4) Connexion aux bases de données et APIs ;
- 5) Intégration souveraine

Pourquoi le RAG ?

Problématique : Les LLM ont une **date de coupure de connaissances** et peuvent halluciner sur des données internes ou spécifiques (ex: offres, incidents techniques, des retours client inventés, etc.).

Solution RAG : **Injecter** dynamiquement les avis clients ou la documentation technique pertinents directement dans le prompt du modèle.

Sécurité & Contexte : Permet de s'appuyer sur des sources vérifiées **sans fine-tuning** lourd.

Architecture de la Recherche Sémantique


Vectorisation (Embeddings) : Transformation du texte en vecteurs numériques pour capturer le sens sémantique (et non plus seulement des mots-clés).

Chunking (Découpage) : Scinder les longs documents en morceaux cohérents pour optimiser la précision de la recherche.

Indexation : Stockage des embeddings dans une base de données vectorielle pour un calcul de distance rapide (recherche par similarité).

Infrastructure & Modèles Ouverts

Hébergement Souverain : Utilisation d'un modèle ouvert (ex: Qwen/Alibaba, Mistral, Phi/Microsoft, etc.) déployé via conteneur Docker sur un serveur propre pour garantir la maîtrise des données.



Orchestration LangChain/LangGraph :

- ☐ Assemblage fluide du récupérateur de données (**Retriever**),
- ☐ Prompt enrichi par les données récupérées
- ☐ LLM pour automatiser les réponses.

Comparatif des Bases de Données Vectorielles

Base Vectorielle	Avantages	Inconvénients	Cas d'usage idéal
 chroma (Chroma DB)	Très simple à installer, idéal pour le prototypage , s'intègre nativement et rapidement avec LangChain.	Moins taillé pour les environnements distribués à très grande échelle en production.	Prototypage rapide, petits/moyens volumes, environnements locaux.
 FAISS (FACEBOOK AI SIMILARITY SEARCH) (Meta)	Extrêmement rapide pour la recherche en mémoire , gère des milliards de vecteurs.	Pas de persistance native simple sans code additionnel, pas une vraie base de données.	Recherche haute performance en mémoire vive (RAM).
PGVector (PostgreSQL)	Permet de combiner données relationnelles et vecteurs dans une seule base (PostgreSQL).	Moins spécialisé pour les recherches vectorielles pures ultra-massives que les solutions dédiées.	Projets d'entreprise utilisant déjà PostgreSQL pour éviter de multiplier les technos.
 milvus  qdrant	Robustes, orientés production, scalables, riches en fonctionnalités (filtrage métadonnées avancé).	Architecture plus complexe à déployer et administrer au quotidien.	Applications industrielles à grande échelle (Production).

Vision selon les profils

Vision Métier (Pour les Managers)

- ❑ **Éviter les hallucinations** : Connecter le LLM aux documents internes de l'entreprise (base de connaissances OCI) pour que l'IA réponde sur des faits avérés et sourcés.
- ❑ **Sémantique vs Mots-clés** : Comprendre l'intérêt de chercher par le "**sens**" plutôt que par **correspondance exacte de mots**.

Implémentation Technique

- ❑ **Indexation vectorielle** : Utilisation de ChromaDB et des embeddings.
- ❑ **Mécanique de recherche** : Calcul de similarité cosinus entre vecteurs de requêtes et chunks documentaires. Comparaison avec FAISS, PGVector et Qdrant.

Lab 4

- ☐ Construction d'un graphe de connaissance télécoms.
- ☐ Intégration réelle avec une base de données simulée contenant des schémas réseaux, des tarifs, ou des **retours clients**.
- ☐ Gestion des "Hallucinations" via le RAG strict.
- ☐ Construire un Agent avec LangChain/LangGraph (Lab 5)
- ☐ Atelier de conception avec n8n