

Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 4

Génération augmentée par la récupération RAG)

Contenu

- 1) Principes du Retrieval-Augmented Generation (RAG) ;
- 2) Construction de bases de connaissances ;
- 3) Recherche sémantique et vectorisation ;
- 4) Connexion aux bases de données et APIs ;
- 5) Cas d'intégration dans l'environnement Orange Côte d'Ivoire.

Pourquoi le RAG ?

Problématique : Les LLM ont une date de coupure de connaissances et peuvent halluciner sur des données internes ou spécifiques (ex: offres, incidents techniques).

Solution RAG : Injecter dynamiquement les avis clients ou la documentation technique pertinents directement dans le prompt du modèle.

Sécurité & Contexte : Permet de s'appuyer sur des sources vérifiées (Dataset *French Customer Review Sentiment*) sans fine-tuning lourd.

Architecture de la Recherche Sémantique

Vectorisation (Embeddings) : Transformation du texte en vecteurs numériques pour capturer le sens sémantique (et non plus seulement des mots-clés).

Chunking (Découpage) : Scinder les longs documents en morceaux cohérents pour optimiser la précision de la recherche.

Indexation : Stockage des embeddings dans une base de données vectorielle pour un calcul de distance rapide (recherche par similarité).

Infrastructure & Modèles Ouverts

Hébergement Souverain : Utilisation d'un modèle ouvert (ex: Qwen) déployé via conteneur Docker (vLLM) sur RunPod pour garantir la maîtrise des données.

Orchestration LangChain :

- ☐ Assemblage fluide du récupérateur (*Retriever*),
- ☐ Prompt enrichi
- ☐ LLM pour automatiser les réponses.