

Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 5

Les Agents IA (Partie 1: Types, Outils, Tool Calling)




Cédric Manouan

Contenu

- 1) Principes de fonctionnement des agents IA;
- 2) Architecture d'un agent intelligent ;
- 3) Agents conversationnels et assistants virtuels ;
- 4) Gestion des outils et des actions (Tool Calling) ;
- 5) Développement de chatbots métier.

Principe de fonctionnement d'un agent IA

Assistant/agent conversationnel/Chatbot (Il parle/génère du texte)




Principe de fonctionnement d'un agent IA

Assistant/ **agent conversationnel**/ Chatbot (Il parle/ génère du texte)

Entrée/Input

- ☐ Exemples
- ☐ Document drafté/Code
- ☐ Source/Base de connaissance pour réduire les hallucinations



Génération


Réponse structurée selon les règles définies par les instructions dans le prompt

Instruction/Prompt Système


- ☐ Prompt définissant ce que l'on attend du chatbot
- ☐ Question

Principe de fonctionnement d'un agent IA (2/2)

Agent = Actions autonomes (**tool calling**); exécution étape par étape jusqu'à complétion (**boucle agentique**).




Rappel: Base de données vectorielle



Principe de fonctionnement d'un agent IA (2/2)

Agent = Actions autonomes (tool calling); exécution étape par étape jusqu'à complétion (boucle agentique).



4 Manière de concevoir des agents IA (1/3)

Catégorie	Profils concernés	Outils / Support	Points clés
No-Code	Managers, Directeurs, opérationnels sans bagage ou volonté de programmation.	Interfaces de chat directes (Playgrounds de LLM)	Pas de programmation; pas besoin d'être technique
Low Code	Personnes ayant des notions de scripts, sans être des développeurs full-stack.	❑ Manipulation de scripts pré-paramétrés (LangChain simple, configuration de prompts dans des fichiers .txt ou .md). ❑ Utilisation d'API (recherche web) et des templates de prompts modulaires.	Savoir modifier un fichier de prompt ajuster la température d'un modèle, et comprendre comment brancher un outil de recherche sémantique (ChromaDB) sans réécrire les algorithmes.

4 Manière de concevoir des agents IA (2/3)

Catégorie	Profils concernés	Outils / Support	Points clés
Harnet (Agent Harness)	Ingénieurs en charge de l'infrastructure, du pipeline de données ou du raccordement des bases de données.	❑ Structuration des actions ❑ Contrôle à distance ou guidé	Customisation d'agent puissants existant
Full Code	Développeurs, IA Engineers, Data Scientists concevant des architectures complexes.	❑ Construction du graphe orienté sous LangGraph. ❑ Utilisation de langgraph_supervisor pour orchestrer dynamiquement le Superviseur, le Chercheur, le Rédacteur et le Vérificateur. ❑ Déploiement hybride : bascule entre inférence locale (Ollama) et serveur distant (cloud).	Le code source complet, modulaire et industrialisable du système multi-agents, prêt à être containerisé sous Docker et déployé en production

4 Manière de concevoir des agents IA (3/3)

Catégorie	Exemples
No-Code	   
Low Code	   
Harness	 
Full code	 

Vision selon les profils

Vision Métier (Pour les Managers)

- ❑ **Passer d'une IA linéaire à une équipe collaborative** : Structurer l'IA pour qu'elle résolve des tâches complexes en faisant intervenir plusieurs rôles spécialisés (Chercheur, Rédacteur, Vérificateur).
- ❑ **Validation Humaine (Human-in-the-loop)** : Garder le contrôle final avant toute action critique (publication de posts réseaux sociaux, requêtes sensibles, envoi de mails, etc.).

Implémentation Technique

- ❑ **Tool Calling natif** : Décorateur (**@tool**) de LangChain.
- ❑ **Validation stricte avec Pydantic** : Utilisation de **schémas de validation séparés**.

Exemple: pour l'analyse des requêtes SQL (séparation stricte entre la validation syntaxique/sémantique et l'exécution de la requête).

Décisions pour motiver le choix (1/2)

Plateforme

- ☐ Pour l'usage selon les besoin

Modèle

- ☐ Type propriétaire ou ouvert (open weights).
- ☐ Claude, GPT, Gemini, etc.

Contexte

- ☐ Quelles informations sont accessibles ? Base de données ? Etc.

Type de contrôle

- ☐ Arbre de décision, types d'outils

Décisions pour motiver le choix (2/2)

Coût

Ces plateformes de création d'agents IA ne sont **pas entièrement gratuit**, mais il **propose un modèle "source-available" (équitable) très flexible** qui les rendent gratuit dans certains cas, notamment pour l'**auto-hébergement**.

- ❑ **Le principe** : Vous téléchargez l'image Docker de n8n et vous l'installez sur votre propre machine (ou un serveur de votre entreprise en local, ou de type AWS, OVH, etc.).
- ❑ **Est-ce gratuit ? Oui**, le code source de base est accessible gratuitement et vous pouvez exécuter autant de workflows et de tâches que vous voulez. Vous payez uniquement le coût de votre serveur.
- ❑ **La limite (Licence Fair-code)** : Vous ne pouvez pas revendre n8n en tant que service managé (vendre du "n8n as a service" à des clients externes). Pour un usage interne en entreprise, **n8n est gratuit à ce jour**.

Lab 5

- ❑ Introduction à LangGraph
- ❑ La logique de graphes : cycles, breaks, conditionnalités
- ❑ LangGraph et workflows complexes
- ❑ Cas Pratique : Conception d'une boucle d'agent autonome où l'agent appelle lui-même les outils sans intervention humaine, géré par un LangGraph.