


Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 7



Déploiement, Industrialisation et Gouvernance



Contenu

- 1) Déploiement des agents IA en production
- 2) Monitoring et supervision ;
- 3) Principes de MLOps et LLMOps ;
- 4) Sécurité, confidentialité et protection des données ;
- 5) Éthique et gouvernance de l'IA ;
- 6) Gestion des risques et conformité.

Déploiement et industrialisation

Architecture et conteneurisation

- ❑ Passage du **prototype local** à un **environnement hébergé** sur serveur virtuel ou cloud.
- ❑ Utilisation de **Docker** et **Kubernetes** pour packager l'application développée ainsi que les dépendances (LangGraph, etc.)



Gestion de la charge, de la persistance, et du scaling

- ❑ **Dimensionnement** des ressources CPU/GPU/RAM pour supporter les **requêtes simultanées** des utilisateurs.
- ❑ Utilisation de checkpointers persistants (**bases de données externes** type PostgreSQL) pour sécuriser l'état des sessions.
- ❑ Séparation des **services d'inférence**, de la **base vectorielle** (ex: ChromaDB) et de l'interface utilisateur.
- ❑ Mise en place de **files d'attente** pour gérer les pics de trafic des équipes métiers.

Monitoring et supervision (1/2)

Observabilité des LLM

- ❑ Suivi des **métriques clés** : latence de réponse, consommation des **tokens** et coûts d'API associés.
- ❑ Utilisation d'outils d'ingénierie (type **LangSmith**) pour **tracer** les exécutions de graphes et les appels d'outils.

Détection des anomalies

- ❑ Surveillance des **boucles** d'outils **infinies** et des **échecs de parsing des réponses** du modèle.
- ❑ Analyse des logs backend en temps réel pour **identifier les erreurs d'exécution** inopinées.

Monitoring et supervision (2/2)

Tableaux de bord opérationnels

- ❑ Centralisation des **indicateurs de santé de l'agent** et de l'état des services distants.
- ❑ **Alertes automatique** en cas de dégradation des performances du système RAG.

Principes de MLOps et LLMOps (1/2)

Industrialisation du cycle de vie

- ❑ Application des **principes d'ingénierie logicielle** aux systèmes à base de LLM (LLMOps).
 - ❑ Modularité, abstraction, séparation des préoccupations (segmentation), réutilisabilité, maintenabilité, etc...
- ❑ Versioning rigoureux des **datasets** bruts (ex: fichiers .csv, .json, etc.), des **scripts** d'ingestion et des **index de recherche**.

Principes de MLOps et LLMOps (2/2)

Dissociation des flux

- ☐ Séparation stricte entre:
 - ☐ les scripts de création/persistance des bases vectorielles (**ingest.py**)
 - ☐ l'application runtime
- ☐ Évite le **retraitement inutile des embeddings** à chaque redémarrage de l'application.

Traçabilité et reproductibilité

- ☐ Suivi des versions des modèles d'embedding et des hyperparamètres de chunking pour garantir la reproductibilité des résultats.

Sécurité, confidentialité et protection des données (1/2)

Gestion des données sensibles (PII)

- ☐ Masquage et **filtrage des informations personnelles** et confidentielles présentes dans les retours clients.
- ☐ Respect des **réglementations locales** sur la protection des données et la confidentialité.

Sécurisation des accès

- ☐ Gestion des **clés API et authentification forte** pour accéder aux modèles de langage et aux serveurs distants.
- ☐ Isolation des environnements de développement et de production.

Sécurité, confidentialité et protection des données (2/2)

Barrières de sécurité (Guardrails)

- ☐ Implémentation de **filtres en amont et en aval** pour bloquer les **injections** de prompts et les **contenus toxiques**.
- ☐ Contrôle strict des permissions d'exécution des outils par l'agent
 - ☐ Exécution de commandes shell, connexion à une base de données, etc.