


Agent IA: Déploiement plateforme, architecture, configuration, utilisation

Module 7



Déploiement, Industrialisation et Gouvernance


Contenu

- 1) Déploiement des agents IA en production
- 2) Monitoring et supervision ;
- 3) Principes de MLOps et LLMOps ;
- 4) Sécurité, confidentialité et protection des données ;
- 5) Éthique et gouvernance de l'IA ;
- 6) Gestion des risques et conformité.
- 7) Discussion & Lab 6

Déploiement et industrialisation

Architecture et conteneurisation

- ❑ Passage du **prototype local** à un **environnement hébergé** sur serveur virtuel ou cloud.
- ❑ Utilisation de **Docker** et **Kubernetes** pour packager l'application développée ainsi que les dépendances (LangGraph, etc.)



Gestion de la charge, de la persistance, et du scaling

- ❑ **Dimensionnement** des ressources CPU/GPU/RAM pour supporter les **requêtes simultanées** des utilisateurs.
- ❑ Utilisation de checkpointers persistants (**bases de données externes** type PostgreSQL) pour sécuriser l'état des sessions.
- ❑ Séparation des **services d'inférence**, de la **base vectorielle** (ex: ChromaDB) et de l'interface utilisateur.
- ❑ Mise en place de **files d'attente** pour gérer les pics de trafic des équipes métiers.

Monitoring et supervision (1/4)

Observabilité des LLM

- ☐ Suivi des **métriques clés** : latence de réponse, consommation des **tokens** et coûts d'API associés.
- ☐ Utilisation d'outils d'ingénierie (type **LangSmith**) pour **tracer** les exécutions de graphes et les appels d'outils.


Détection des anomalies

- ☐ Surveillance des **boucles** d'outils **infinies** et des **échecs de parsing des réponses** du modèle.
- ☐ Analyse des logs backend en temps réel pour **identifier les erreurs d'exécution** inopinées.

Monitoring et supervision (2/4)


Observabilité des LLM

- ❑ Suivi des **métriques clés** :
latence de réponse,
consommation des **tokens** et
coûts d'API associés.
- ❑ Utilisation d'outils d'ingénierie
(type **LangSmith**) pour **tracer**
les exécutions de graphes et les
appels d'outils.



<https://www.langchain.com/langsmith-platform>

Monitoring et supervision (3/4)



Source: <https://medium.com/agentive-builders/langsmith-explained-the-complete-guide-to-the-agent-development-lifecycle-02e0894f253f>

Monitoring et supervision (4/4)

Détection des anomalies

- ☐ Surveillance des **boucles** d'outils **infinies** et des **échecs de parsing des réponses** du modèle.
- ☐ Analyse des logs backend en temps réel pour **identifier les erreurs d'exécution** inopinées.

Tableaux de bord opérationnels

- ☐ Centralisation des **indicateurs de santé de l'agent** et de l'état des services distants.
- ☐ **Alertes automatique** en cas de dégradation des performances du système RAG.

Principes de MLOps et LLMOps (1/2)

Industrialisation du cycle de vie

- ❑ Application des **principes d'ingénierie logicielle** aux systèmes à base de LLM (LLMOps).
 - ❑ Modularité, abstraction, séparation des préoccupations (segmentation), réutilisabilité, maintenabilité, etc...
- ❑ Versioning rigoureux des **datasets** bruts (ex: fichiers .csv, .json, etc.), des **scripts** d'ingestion et des **index de recherche**.

Principes de MLOps et LLMOps (2/2)

Dissociation des flux

- ☐ Séparation stricte entre:
 - ☐ les scripts de création/persistance des bases vectorielles (**ingest.py**)
 - ☐ l'application runtime
- ☐ Évite le **retraitement inutile des embeddings** à chaque redémarrage de l'application.

Traçabilité et reproductibilité

- ☐ Suivi des versions des modèles d'embedding et des hyperparamètres de chunking pour garantir la reproductibilité des résultats.

Sécurité, confidentialité et protection des données (1/2)

Gestion des données sensibles (PII)

- ☐ Masquage et **filtrage des informations personnelles** et confidentielles présentes dans les retours clients.
- ☐ Respect des **réglementations locales** sur la protection des données et la confidentialité.

Sécurisation des accès

- ☐ Gestion des **clés API et authentification forte** pour accéder aux modèles de langage et aux serveurs distants.
- ☐ Isolation des environnements de développement et de production.

Sécurité, confidentialité et protection des données (2/2)

Barrières de sécurité (Guardrails)

- ☐ Implémentation de **filtres en amont et en aval** pour bloquer les **injections** de prompts et les **contenus toxiques**.
- ☐ Contrôle strict des permissions d'exécution des outils par l'agent
 - ☐ Exécution de commandes shell, connexion à une base de données, etc.

Contenu (suite)

- 1) Déploiement des agents IA en production
- 2) Monitoring et supervision ;
- 3) Principes de MLOps et LLMOps ;
- 4) Sécurité, confidentialité et protection des données ;
- 5) Éthique et gouvernance de l'IA ;
- 6) Gestion des risques et conformité.
- 7) Discussion & Lab 6

Éthique et gouvernance de l'IA (1/3)

Transparence et explicabilité

- ☐ Garantie de l'**auditabilité des décisions prises par l'agent** grâce à l'**affichage des sources** exactes.
- ☐ Lutte contre les "boîtes noires" en associant chaque réponse analytique à ses documents d'origine.

Alignement organisationnel


- ☐ Respect des **chartes éthiques** et des **directives de l'entreprise** dans le ton et le contenu des réponses.
- ☐ Supervision humaine (**Human-in-the-loop**) pour valider les décisions critiques.

Éthique et gouvernance de l'IA (2/3)

Équité et non-discrimination

- ☐ Analyse des **biais potentiels dans les datasets d'évaluation** pour assurer un traitement neutre des requêtes.
- ☐ Veille sur l'**impact de l'outil** auprès des différents métiers et utilisateurs finaux.

Éthique et gouvernance de l'IA (3/3)



Source: Koba Pascal Ohounlome, <https://journals.openedition.org/ctd/15875>

Gestion des risques et conformité (1/2)

Maîtrise des hallucinations

- ☐ Utilisation de **températures** d'exécution strictes (temperature=0 selon les cas d'usage) et de **prompts contraignants** pour limiter les dérives.
- ☐ Ancrage des réponses fondé exclusivement sur les faits récupérés par le RAG (**RAG Strict**).

Conformité réglementaire

- ☐ **Alignement** avec les cadres juridiques en vigueur régissant l'usage de l'intelligence artificielle et la recherche.
- ☐ Documentation des processus de prise de décision algorithmique.

Gestion des risques et conformité (2/2)

Les trois niveaux d'alignement de l'IA en entreprise

- ❑ **Les objectifs** : Définir clairement le **but premier** et les **critères de réussite** de l'agent.
- ❑ **Les principes** : **Hiérarchiser les valeurs** et les **règles d'arbitrage** en cas de consignes conflictuelles.
- ❑ **Les pratiques** : Intégrer les workflows, les normes universelles et les régulations sectorielles pour encadrer l'exécution.


Plan de mitigation des risques

- ❑ Identification proactive des **points de défaillance** technique et des **risques de non-conformité** des données.
- ❑ Protocoles de secours (alternatif) en cas d'indisponibilité des modèles cloud ou de corruption de la base vectorielle.

Pourquoi n'avez-vous pas conçu de agents IA auparavant ?

La quasi totalité des projets pilote IA échouent (1/4)

Jusqu'à **95 % des projets pilotes** d'IA générative en entreprise **ne parviennent pas à offrir des retours financiers** mesurables ni à atteindre la production.



La quasi totalité des projets pilote IA échouent (2/4)

Jusqu'à 95 % des projets pilotes d'IA générative en entreprise ne parviennent pas à offrir des retours financiers mesurables ni à atteindre la production.

Pourquoi?

- ❑ **Approche Tech-First:** Les organisations **choisissent un outil ou un modèle** comme un chatbot **avant de définir un problème** métier spécifique ou une métrique de référence.
- ❑ **Isolation des flux de travail (workflow):** Les applications d'IA **fonctionnent comme des fenêtres de chat autonomes** au lieu d'être intégrées directement dans les flux de travail principaux de l'entreprise et les systèmes connectés.

La quasi totalité des projets pilote IA échouent (3/4)

Écarts de préparation des données

- ☐ La plupart des entreprises manquent de **données « propres », structurées ou prêtes pour l'IA**
- ☐ Cela crée un environnement propice aux **erreurs** contextuelles et aux **hallucinations**.

L'angle mort du passage à l'échelle (scaling)


Les équipes construisent **des prototypes fonctionnels en quelques semaines**, mais ne franchissent pas les obstacles de conformité, de gestion juridique, de gestion des risques ou d'intégration en production

La quasi totalité des projets pilote IA echouent (4/4)

Comment réaliser une adoption efficace de l'IA

- ☐ Lier chaque projet à une métrique opérationnelle stricte, comme une réduction du temps de traitement d'un pourcentage défini.
- ☐ Se concentrer sur l'intégration des données et l'alignement des flux de travail avant d'intégrer des agents d'automatisation avancée ou d'IA.
- ☐ Impliquer dès le premier jour les équipes juridiques, de sécurité et de conformité plutôt que de considérer la gouvernance comme une réflexion secondaire.
- ☐ Poursuivre quelques cas d'usage profonds et à fort impact au lieu de disperser des outils non guidés à travers le personnel.

L'histoire jusqu'à présent...



Quelques Ressources Utiles

Documentation officielle n8n : Guide complet pour comprendre comment intégrer des agents, des outils et des modèles de langage dans des workflows visuels low-code.

Tutoriels et templates n8n AI : Bibliothèque officielle de modèles prêts à l'emploi pour créer des agents conversationnels et des assistants RAG
<https://n8n.io/workflows/categories/ai/>.

Blog et cas d'usage n8n sur l'IA : Articles pratiques détaillant la mise en place d'architectures multi-agents et la connexion aux bases vectorielles
<https://blog.n8n.io/tag/ai/>.

Cours DeepLearning.AI (en ligne) : Formations de référence sur les fondamentaux des LLM et le développement d'agents autonomes, dispensées par Andrew Ng [DeepLearning.AI](https://www.deeplearning.ai).

MIT Introduction à l'apprentissage profond: [MIT 6S191 sur Youtube \[Anglais\]](https://www.youtube.com/watch?v=JG1yVdQW0Y0)